Entrega Big Data Architecture

Entregable parte 1:

```
ruijiagu@cluster-hadoop-practica-m:~$ gsutil cp gs://bucket-para-elastic-practica/jars/ela
stic/elasticsearch-hadoop-8.14.1.jar .
Copying gs://bucket-para-elastic-practica/jars/elastic/elasticsearch-hadoop-8.14.1.jar...
/ [1 files][ 2.1 MiB/ 2.1 MiB]
Operation completed over 1 objects/2.1 MiB.
ruijiagu@cluster-hadoop-practica-m:~$ gsutil cp gs://bucket-para-elastic-practica/jars/ela
stic/commons-httpclient-3.1.jar .
Copying gs://bucket-para-elastic-practica/jars/elastic/commons-httpclient-3.1.jar...
/ [1 files][297.8 KiB/297.8 KiB]
Operation completed over 1 objects/297.8 KiB.
ruijiagu@cluster-hadoop-practica-m:~$ ls -ltr
total 2472
-rw-r--r-- 1 ruijiagu ruijiagu 2224041 Oct 12 12:19 elasticsearch-hadoop-8.14.1.jar
-rw-r--r-- 1 ruijiagu ruijiagu 305001 Oct 12 12:20 commons-httpclient-3.1.jar
```

Entregable Parte 2:

```
# Enable security features
xpack.security.enabled: false
xpack.security.enrollment.enabled: true
# Enable encryption for HTTP API client connections, such as Kibana, Logstash, and Agents
xpack.security.http.ssl:
enabled: false
  keystore.path: certs/http.p12
# Enable encryption and mutual authentication between cluster nodes
xpack.security.transport.ssl:
 enabled: true
 verification_mode: certificate
 keystore.path: certs/transport.p12
 truststore.path: certs/transport.p12
# Create a new cluster with the current node only
# Additional nodes can still join the cluster later
cluster.initial_master_nodes: ["vm-para-elastic-practica"]
# Allow HTTP API connections from anywhere
# Connections are encrypted and require user authentication
http.host: 0.0.0.0
# Allow other nodes to join the cluster from anywhere
# Connections are encrypted and mutually authenticated
#transport.host: 0.0.0.0
```

Entregable parte 3:

```
ruijiagu@cluster-hadoop-practica-m:~$ sudo sed -i '$d' /etc/hive/conf.dist/hive-site.xml
ruijiagu@cluster-hadoop-practica-m:~$ sudo cat /etc/hive/conf.dist/hive-site.xml
```

Aquí he ejecutado un sudo cat para ver el contenido antes de realizar los cambios (más precisamente, después de eliminar la última línea del archivo de configuración y antes de aplicar el resto de las modificaciones).

```
ruijagu@cluster-hadoop-practica-m:-$ sudo sed -i '$a \ property>\n' /etc/hive/conf.dist/hive-site.xml
ruijagu@cluster-hadoop-practica-m:-$ sudo sed -i '$a \ yroperty>\n' /etc/hive/conf.dist/hive-site.xml
ruijagu@cluster-hadoop-practica-m:-$ sudo sed -i '$a \ yroperty>\n' /etc/hive/conf.dist/hive-site.xml
```

```
<name>es.nodes
<value>AQUÍ LA IP DE ELASTIC</value>
```

Aquí, al ver el resultado del sudo cat, me di cuenta de que no había puesto la IP de ELASTIC, por lo que después utilicé sudo nano para abrir el archivo y añadirla.

```
ruijiagu@cluster-hadoop-practica-m:-$ sudo nano /etc/hive/conf.dist/hive-site.xml
ruijiagu@cluster-hadoop-practica-m:-$ sudo cat /etc/hive/conf.dist/hive-site.xml
```

Después de editar la IP con sudo nano, en el resultado de sudo cat ya puedo comprobar que la IP de ELASTIC está correctamente colocada.

```
<name>es.nodes</name>
      <value>34.175.246.18</value>
```

Continué con el resto de la configuración.

Al final, después de reiniciar Hive, ejecuté un systemctl para comprobar su estado.

Además de eso, ejecuté un sudo cat al finalizar toda la configuración, y así es como se ve el archivo de configuración después de realizar todos los cambios. (Solo muestro la parte final del archivo, que corresponde a los cambios que realizamos.).

```
</property>
cproperty>
  <name>hive.exec.input.listing.max.threads</name>
  <value>20</value>
</property>
cproperty>
  <name>hive.fetch.task.conversion</name>
<value>minimal</value>
</property>
cproperty>
  <name>es.nodes</name>
  <value>34.175.246.18</value>
</property>
cproperty>
  <name>es.port</name>
  <value>9200</value>
</property>
cproperty>
  <name>es.nodes.wan.only</name>
  <value>true</value>
</property>
cproperty>
 <p
</property>
</configuration>
```

Entregable parte 4:

Entregable parte 5:

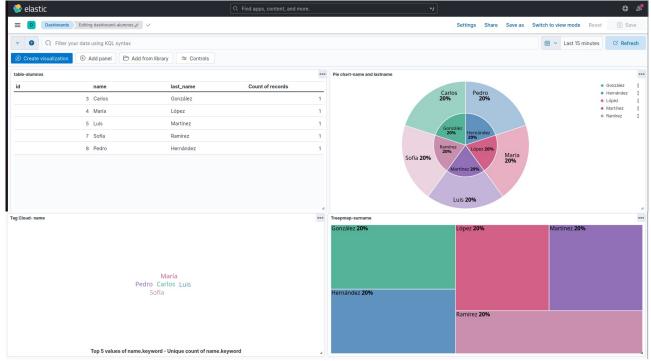
Al observar los datos, noté que solo contienen el nombre, el apellido y el ID de cada alumno. Por ello, he creado una tabla que muestra los nombres y apellidos de todos ellos.

Cuando se arrastra un campo de texto (como last_name keyword) a "Rows", Kibana aplica automáticamente una agregación de tipo "Top values", es decir, solo muestra los *N* valores más frecuentes (por defecto, los cinco primeros). En este caso, para visualizar todas las filas, seleccioné "Top 5 values" (ya que tenemos cinco alumnos en total) y luego cambié el nombre de las columnas a id, name y last_name para que sean legibles.

Para experimentar un poco con los gráficos, también creé un gráfico circular (Pie chart) para visualizar el porcentaje de nombres y apellidos (cada uno representa un 20 %, ya que no se repite ningún nombre ni apellido).

Además, elaboré una nube de etiquetas (Tag cloud) con los nombres y un Treemap con los apellidos.

Finalmente, el dashboard se ve así:



También importé el conjunto de datos *shakespeare.json* en Kibana para analizar y experimentar con distintas visualizaciones.

